

Интерпретация работы Vision-Language моделей

Часть 1: Работа с CLIP

- Загрузите предобученную модель CLIP (OpenAI CLIP или OpenCLIP). В качестве альтернативы можно использовать Ваш любимый энкодер, на примере которого можно выполнить задание.
- Выберите 5–10 пар изображение + текстовое описание. Можно взять из открытых датасетов (например, Flickr30k) или создать вручную.
- Получите визуальные и текстовые эмбединги, посчитайте их схожесть (например, cosine similarity).
- Визуализируйте результаты: покажите, как модель 'понимает' соответствие между изображением и текстом.

Часть 2: Интерпретация

- Примените один из базовых методов интерпретации (например, Grad-CAM или attention rollout) к image encoder модели CLIP.
- Покажите, какие области изображения важны для соответствия с заданным текстом.
- Проанализируйте: насколько интерпретация кажется разумной? Есть ли отличия между разными текстами к одному изображению?

Что будет оцениваться

- Корректность и аккуратность кода в Jupyter notebook;
- Способность работать с pre-trained моделями;
- Умение применять методы интерпретации и визуализации;
- Аналитические выводы по результатам эксперимента;
- Стиль и структура отчета (ясно, кратко, по существу).

Дополнительные бонусы (необязательно, но приветствуются)

- Использование Grad-CAM++ или других современных методов;
- Сравнение результатов нескольких описаний к одному изображению;
- Попытка визуализировать внутренние attention map'ы из CLIP;
- Подготовка интерактивного дашборда или видео с демонстрацией.

Формат выполнения

Jupyter Notebook с решением, пояснениями, артефактами работы и всеми выводами.